

Politechnika Rzeszowska

# Modelowanie i prognozowanie cen gazu TTF

Analiza ekonometryczna wielowymiarowa: ARIMAX + GARCH-X + kointegracja

Maciek Gilecki, Wioletta Grabias

24.05.2026

## Spis treści

|                                                           |           |
|-----------------------------------------------------------|-----------|
| <b>1 Konfiguracja środowiska</b>                          | <b>1</b>  |
| 1.1 Instalacja i wczytanie pakietów . . . . .             | 1         |
| 1.2 Parametry projektu . . . . .                          | 1         |
| <b>2 Wprowadzenie</b>                                     | <b>2</b>  |
| 2.1 Kontekst ekonomiczny . . . . .                        | 2         |
| 2.2 Mechanizm rynku — analiza popytu i podaży . . . . .   | 2         |
| 2.3 Cel projektu . . . . .                                | 4         |
| 2.4 Hipotezy badawcze . . . . .                           | 4         |
| <b>3 Pobranie i przygotowanie danych</b>                  | <b>4</b>  |
| 3.1 Źródła danych . . . . .                               | 4         |
| 3.2 Uzasadnienie ekonomiczne wyboru zmiennych . . . . .   | 4         |
| 3.3 Brent i EUR/USD (FRED) . . . . .                      | 6         |
| 3.4 Pogoda i HDD (Open-Meteo) . . . . .                   | 6         |
| 3.5 Zapasy gazu UE (AGSI+ — ręczny eksport CSV) . . . . . | 8         |
| 3.6 TTF (Kaggle / Investing.com) . . . . .                | 9         |
| 3.7 Scalenie i raport jakości . . . . .                   | 10        |
| 3.8 Statystyki opisowe . . . . .                          | 11        |
| <b>4 Analiza eksploracyjna (EDA)</b>                      | <b>11</b> |
| 4.1 Wykresy szeregów . . . . .                            | 11        |
| 4.2 Log-stopowy zwrot i pierwsze różnice . . . . .        | 14        |
| 4.3 Korelacje . . . . .                                   | 16        |

|           |                                                                 |           |
|-----------|-----------------------------------------------------------------|-----------|
| <b>5</b>  | <b>Testy stacjonarności</b>                                     | <b>16</b> |
| <b>6</b>  | <b>Selekcja zmiennych objaśniających</b>                        | <b>18</b> |
| 6.1       | Metodologia selekcji . . . . .                                  | 18        |
| 6.2       | Krok 1 — Test współliniowości (VIF) . . . . .                   | 18        |
| 6.3       | Krok 2 — Istotność regresorów (test t) . . . . .                | 19        |
| 6.4       | Krok 3 — Eliminacja wsteczna (general-to-specific) . . . . .    | 20        |
| 6.5       | Krok 4 — Porównanie modeli zagnieżdżonych (AIC / BIC) . . . . . | 22        |
| 6.6       | Wnioski z procedury selekcji . . . . .                          | 23        |
| <b>7</b>  | <b>Analiza kointegracji</b>                                     | <b>24</b> |
| 7.1       | Engle-Granger (TTF vs Brent) . . . . .                          | 24        |
| 7.2       | Phillips-Ouliaris . . . . .                                     | 24        |
| 7.3       | Johansen (TTF, Brent, EUR/USD) . . . . .                        | 26        |
| <b>8</b>  | <b>Identyfikacja ARIMA</b>                                      | <b>27</b> |
| <b>9</b>  | <b>Estymacja ARIMA i ARIMAX</b>                                 | <b>29</b> |
| 9.1       | Model bazowy: ARIMA jednowymiarowy . . . . .                    | 29        |
| 9.2       | Model rozszerzony: ARIMAX . . . . .                             | 29        |
| 9.3       | Porównanie ARIMA vs ARIMAX . . . . .                            | 31        |
| 9.4       | Diagnostyka reszt ARIMAX . . . . .                              | 31        |
| <b>10</b> | <b>Test efektu ARCH</b>                                         | <b>33</b> |
| <b>11</b> | <b>Estymacja modelu GARCH-X</b>                                 | <b>35</b> |
| 11.1      | sGARCH(1,1) bazowy (bez X) . . . . .                            | 35        |
| 11.2      | sGARCH(1,1)-X — pełny . . . . .                                 | 38        |
| 11.3      | Diagnostyka GARCH-X . . . . .                                   | 40        |
| 11.4      | Porównanie wariantów GARCH . . . . .                            | 43        |
| <b>12</b> | <b>Walidacja out-of-sample</b>                                  | <b>44</b> |
| 12.1      | Walk-forward dla ARIMA / ARIMAX . . . . .                       | 44        |
| 12.2      | Test Diebolda-Mariano . . . . .                                 | 45        |
| 12.3      | Wizualizacja prognoz OOS . . . . .                              | 45        |
| <b>13</b> | <b>Prognoza przyszła</b>                                        | <b>46</b> |
| 13.1      | ARIMAX (h = 30 dni) . . . . .                                   | 46        |
| 13.2      | GARCH-X (zmiennosc warunkowa) . . . . .                         | 48        |

|                                         |    |
|-----------------------------------------|----|
| 14 Podsumowanie i wnioski               | 50 |
| 14.1 Weryfikacja hipotez                | 50 |
| 14.2 Wnioski kluczowe                   | 51 |
| 14.3 Ograniczenia i kierunki rozszerzeń | 52 |

# Konfiguracja środowiska

## 1.1 Instalacja i wczytanie pakietów

```
required_packages <- c(
  # Manipulacja danymi
  "tidyverse", "lubridate", "zoo", "readr",
  # Pobieranie i I/O
  "quantmod", "httr", "jsonlite",
  # Modelowanie ekonometryczne
  "forecast", "tseries", "FinTS", "rugarch", "urca",
  # Statystyka, wizualizacja, raporty
  "moments", "xts", "patchwork", "GGally",
  "knitr", "kableExtra"
)

to_install <- setdiff(required_packages, rownames(installed.packages()))
if (length(to_install) > 0) {
  install.packages(to_install, repos = "https://cloud.r-project.org")
}
invisible(lapply(required_packages, library, character.only = TRUE))

theme_set(theme_minimal(base_size = 11))
```

## 1.2 Parametry projektu

```
START_DATE <- as.Date("2015-01-01")
END_DATE <- as.Date("2024-11-29")

RAW_DIR <- file.path("data", "raw")
PROC_DIR <- file.path("data", "processed")
dir.create(RAW_DIR, showWarnings = FALSE, recursive = TRUE)
dir.create(PROC_DIR, showWarnings = FALSE, recursive = TRUE)

cat("Zakres analizy:", as.character(START_DATE), "-", as.character(END_DATE), "\n")

## Zakres analizy: 2015-01-01 - 2024-11-29
```

## 2 Wprowadzenie



### 2.1 Kontekst ekonomiczny

Title Transfer Facility (TTF) to holenderski wirtualny hub gazowy — główny benchmark cen gazu ziemnego w Europie. Notowania wyrażane są w EUR/MWh i odzwierciedlają równowagę popytu i podaży na rynku europejskim. Dynamika cen TTF jest determinowana przez czynniki popytowe (temperatura, aktywność przemysłowa), podażowe (zapasy magazynowe, dostawy rurociągowo, import LNG), makroekonomiczne (kurs EUR/USD, ceny ropy Brent) oraz geopolityczne (konflikty, sankcje, decyzje regulacyjne).

Szczególnym przypadkiem był rok 2022, gdy odcięcie dostaw z Rosji doprowadziło do wzrostu cen TTF do ponad 300 EUR/MWh (sierpień 2022) i dramatycznego wzrostu zmienności szeregu czasowego.

### 2.2 Mechanizm rynku — analiza popytu i podaży

Klasyczna analiza mikroekonomiczna pokazuje, jak szoki popytowe i podażowe wpływają na cenę równowagi rynkowej.



Rysunek 1: Wpływ szoków popytowych i podażyowych na rynek gazu TTF

**Panel A:** mroźna zima przesuwą krzywą popytu w prawo — wyższa cena, wyższy wolumen. **Panel B:** odcięcie dostaw 2022 przesuwą krzywą podaży w lewo — wyższa cena, niższy wolumen.

## 2.3 Cel projektu

Zbudowanie wielowymiarowego modelu ekonometrycznego prognozującego cenę i zmienność gazu TTF, w oparciu o regresory fundamentalne: cenę ropy Brent, kurs EUR/USD, poziom zapasów magazynowych UE oraz indeks Heating Degree Days (HDD).

## 2.4 Hipotezy badawcze

- **H1:** Szereg cen TTF jest niestacjonarny ( $I(1)$ ) i wymaga różnicowania.
- **H2:** Między cenami TTF, Brent i EUR/USD istnieje długookresowa relacja kointegrująca.
- **H3:** W resztach modelu ARIMAX występuje istotny efekt ARCH.
- **H4:** Model GARCH(1,1)-X z poziomem zapasów w równaniu wariancji wyjaśnia heteroskedastyczność lepiej niż klasyczny sGARCH(1,1).
- **H5:** Włączenie regresorów fundamentalnych istotnie poprawia jakość prognozy out-of-sample względem modelu jednowymiarowego (test Diebolda-Mariano).

## 3 Pobranie i przygotowanie danych

### 3.1 Źródła danych

| Zmienna     | Opis                               | Źródło                        | Plik                                 |
|-------------|------------------------------------|-------------------------------|--------------------------------------|
| TTF         | Cena front-month TTF [EUR/MWh]     | Investing.com / Kaggle        | <code>data/raw/ttf.csv</code>        |
| Brent       | Ropa Brent [USD/bbl]               | FRED DCOILBRETEU              | pobierane online                     |
| EURUSD      | USD za 1 EUR                       | FRED DEXUSEU                  | pobierane online                     |
| Storage_pct | % wypełnienia magazynów UE         | AGSI+ (eksport CSV ze strony) | <code>data/raw/storage_eu.csv</code> |
| HDD         | Heating Degree Days (Europa Zach.) | Open-Meteo Historical         | pobierane online                     |

Wszystkie szeregi pobierane online są cache'owane do `data/raw/` — drugi knit nie powtarza pobierania.

### 3.2 Uzasadnienie ekonomiczne wyboru zmiennych

Dobór regresorów nie jest dowolny — każda zmienna ma jednoznaczne, *a priori* ekonomiczne uzasadnienie zakorzenione w teorii rynku surowców energetycznych i potwierdzone w literaturze empirycznej (Geman 2005, Pindyck 2001, Asche et al. 2017, Heather 2019). Spodziewane znaki współczynników wynikają z konkretnych mechanizmów rynkowych:

| Zmienna               | Mechanizm ekonomiczny                                                                                                                                                                                                                                                                      | Znak |
|-----------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|
| $\log(\text{Brent})$  | (1) Substytucyjność energetyczna gazu i ropy w energetyce, petrochemii i transporcie; (2) <b>indeksacja LNG do ropy</b> — część kontraktów długoterminowych nadal stosuje slope ok. 10–13% $\times$ Brent; (3) wspólne czynniki kosztowe (transport, ubezpieczenia, ryzyko geopolityczne). | +    |
| $\log(\text{EURUSD})$ | Kontrakty LNG i nominalna cena Brent są denominowane w <b>USD</b> . Deprecjacja EUR (spadek EURUSD) $\rightarrow$ droższy import w EUR $\rightarrow$ presja wzrostowa na cenę TTF. Mocniejszy EUR działa odwrotnie.                                                                        | —    |
| Storage_pct           | <i>Theory of storage</i> (Working 1933, Pindyck 2001): niskie zapasy $\rightarrow$ wysoka <b>convenience yield</b> $\rightarrow$ wysoka cena spot. Wskaźnik napelnienia magazynów UE jest bezpośrednim sygnałem napięcia popyt-podaż.                                                      | —    |
| HDD                   | Heating Degree Days mierzy bezpośrednio <b>popyt na ogrzewanie</b> . W UE ok. 40% zużycia gazu trafia do sektora bytowo-komunalnego; każdy dodatkowy HDD zwiększa krótkookresowy popyt.                                                                                                    | +    |

Świadomie *nie* włączamy niektórych potencjalnie istotnych zmiennych:

- **Cena prądu (np. niemiecki Baseload)** — w europejskim merit-order to gaz często ustawia cenę krańcową prądu, więc relacja jest endogeniczna; włączenie tej zmiennej wprowadziłoby *simultaneity bias*.
- **Import LNG / przepływy rurociągowy (Entry-Exit)** — dostępne tylko w częstotliwości miesięcznej; włączenie do modelu dziennego wymagałoby interpolacji ad hoc lub modelu mixed-frequency (MIDAS).
- **Henry Hub (USA)** — po 2022 r. silnie skointegrowany globalnie z Brent, duplikowałby informację cenową; ponadto arbitraż LNG transferuje szok HH do TTF z opóźnieniem, którego nie modeluje statyczny regresor.

- **CO EUA (uprawnienia do emisji)** — wpływa na koszty alternatywy węglowej, ale efekt jest pośredni i podlega silnym szokom regulacyjnym (rezerwa MSR, fit-for-55), trudnym do oddzielenia od trendu cenowego TTF.

Formalna weryfikacja, czy te *a priori* wybrane regresory są również **statystycznie istotne** (i czy nie występuje wśród nich współliniowość), odbywa się w **sekcji 6: *Selekcja zmiennych objaśniających*** — bezpośrednio po sprawdzeniu stacjonarności, a przed właściwym modelowaniem ekonometrycznym (kointegracja, ARIMA, ARIMAX, GARCH).

### 3.3 Brent i EUR/USD (FRED)

```
fred_path_brent <- file.path(RAW_DIR, "brent.csv")
fred_path_eurusd <- file.path(RAW_DIR, "eurusd.csv")

# --- Brent ---
if (!file.exists(fred_path_brent)) {
  download.file(
    "https://fred.stlouisfed.org/graph/fredgraph.csv?id=DCOILBRETEU",
    destfile = fred_path_brent, mode = "wb", quiet = TRUE
  )
}
brent <- read_csv(fred_path_brent, show_col_types = FALSE) |>
  rename(Date = 1, Brent = 2) |>
  mutate(Date = as.Date(Date), Brent = as.numeric(Brent)) |>
  filter(!is.na(Brent), Date >= START_DATE, Date <= END_DATE)

# --- EUR/USD ---
if (!file.exists(fred_path_eurusd)) {
  download.file(
    "https://fred.stlouisfed.org/graph/fredgraph.csv?id=DEXUSEU",
    destfile = fred_path_eurusd, mode = "wb", quiet = TRUE
  )
}
eurusd <- read_csv(fred_path_eurusd, show_col_types = FALSE) |>
  rename(Date = 1, EURUSD = 2) |>
  mutate(Date = as.Date(Date), EURUSD = as.numeric(EURUSD)) |>
  filter(!is.na(EURUSD), Date >= START_DATE, Date <= END_DATE)

cat("Brent :", nrow(brent), "obs.\n")
```

```
## Brent : 2520 obs.
```

```
cat("EURUSD :", nrow(eurusd), "obs.\n")
```

```
## EURUSD : 2477 obs.
```

### 3.4 Pogoda i HDD (Open-Meteo)

Heating Degree Days liczone jako  $\max(18 - T_{mean}, 0)$ , ważone udziałem poszczególnych aglomeracji w europejskim popycie gazowym.



```

weather_path <- file.path(RAW_DIR, "weather_hdd.csv")

EU_CITIES <- tibble(
  city = c("Frankfurt", "Paris", "Amsterdam", "London", "Brussels", "Milan"),
  lat = c(50.11, 48.85, 52.37, 51.51, 50.85, 45.46),
  lon = c(8.68, 2.35, 4.90, -0.13, 4.35, 9.19),
  weight = c(0.35, 0.20, 0.10, 0.20, 0.05, 0.10)
)

fetch_year_chunk <- function(lat, lon, year_start, year_end, max_tries = 3) {
  last_err <- NULL
  for (attempt in seq_len(max_tries)) {
    resp <- tryCatch(
      GET(
        "https://archive-api.open-meteo.com/v1/archive",
        query = list(
          latitude = lat, longitude = lon,
          start_date = year_start, end_date = year_end,
          daily = "temperature_2m_mean",
          timezone = "Europe/Berlin"
        ),
        config(connecttimeout = 30),
        httr::timeout(180)
      ),
      error = function(e) { last_err <- e; NULL }
    )
    if (!is.null(resp) && status_code(resp) == 200) {
      j <- fromJSON(content(resp, "text", encoding = "UTF-8"))
      return(tibble(
        Date = as.Date(j$daily$time),
        tmean = as.numeric(j$daily$temperature_2m_mean)
      ))
    }
    Sys.sleep(2 * attempt)
  }
  stop(if (!is.null(last_err)) conditionMessage(last_err) else "HTTP error")
}

fetch_city_chunked <- function(city, lat, lon, weight) {
  years <- seq(year(START_DATE), year(END_DATE))
  cat(" ", city, "(", length(years), "lat) ")
  parts <- list()
  for (yr in years) {
    yr_start <- max(as.Date(paste0(yr, "-01-01")), START_DATE)
    yr_end <- min(as.Date(paste0(yr, "-12-31")), END_DATE)
    parts[[as.character(yr)] <- fetch_year_chunk(lat, lon,
                                                  format(yr_start, "%Y-%m-%d"),
                                                  format(yr_end, "%Y-%m-%d"))
  }
  cat(" ".)
  cat(" OK\n")
  bind_rows(parts) |> mutate(weight = weight, city = city)
}

```

```

if (!file.exists(weather_path)) {
  weather <- tryCatch({
    rows <- purrr::pmap_dfr(EU_CITIES, fetch_city_chunked)
    rows |>
      filter(!is.na(tmean)) |>
      group_by(Date) |>
      summarise(T_mean_EU = sum(tmean * weight) / sum(weight), .groups = "drop") |>
      mutate(HDD = pmax(18 - T_mean_EU, 0)) |>
      arrange(Date)
  },
  error = function(e) {
    message("UWAGA: pobieranie pogody nie powiodlo sie: ", conditionMessage(e))
    message("Kontynuuj BEZ HDD - model bedzie mial 4 zmienne zamiast 5.")
    NULL
  })

  if (!is.null(weather)) write_csv(weather, weather_path)
} else {
  weather <- read_csv(weather_path, show_col_types = FALSE)
}

if (!is.null(weather)) {
  cat("Pogoda :", nrow(weather), "obs.\n")
} else {
  cat("Pogoda : POMINIETA (problem z Open-Meteo)\n")
}

```

```
## Pogoda : 3621 obs.
```

### 3.5 Zapasy gazu UE (AGSI+ — ręczny eksport CSV)

Plik `data/raw/storage_eu.csv` ściągany ze strony <https://agsi.gie.eu/data-overview/EU> (przycisk *Download CSV*). Parser auto-wykrywa separator i nazwy kolumn.

```

# Szukamy pliku po wzorcach: storage_eu.csv, agsi*.csv, StorageData_GIE_*.csv
storage_candidates <- c(
  list.files(RAW_DIR, pattern = "~storage.*\\.csv$",          full.names = TRUE, ignore.case = TRUE),
  list.files(RAW_DIR, pattern = "agsi.*\\.csv$",             full.names = TRUE, ignore.case = TRUE),
  list.files(RAW_DIR, pattern = "~StorageData.*\\.csv$",      full.names = TRUE, ignore.case = TRUE)
)
storage_path <- storage_candidates[1]

if (!is.na(storage_path) && file.exists(storage_path)) {
  first_line <- readLines(storage_path, n = 1, warn = FALSE)
  sep <- if (length(gregexpr(";", first_line)[[1]]) >
    length(gregexpr(",", first_line)[[1]])) ";" else ","

  raw_storage <- read.csv(storage_path, sep = sep, stringsAsFactors = FALSE,
    check.names = FALSE, na.strings = c("", "NA", "-"))

  # "Gas Day Start (...)", "Gas Day", "gasDayStart", "Date"...
  date_col <- names(raw_storage)[grepl("gas\\s*day|^date$|gasdaystart",

```

```

names(raw_storage), ignore.case = TRUE)][1]
# "Full (%)", "Full", "Storage_pct"...
full_col <- names(raw_storage)[grepl("full", names(raw_storage),
                                     ignore.case = TRUE)][1]

if (is.na(date_col) || is.na(full_col)) {
  warning("Nie rozpoznano kolumn w ", basename(storage_path),
          " - dostępne: ", paste(names(raw_storage), collapse = ", "))
  storage <- NULL
} else {
  storage <- tibble(
    Date = as.Date(parse_date_time(raw_storage[[date_col]],
                                    orders = c("ymd", "dmy", "mdy"))),
    Storage_pct = as.numeric(gsub(",", ".", as.character(raw_storage[[full_col]])))
  ) |>
  filter(!is.na(Date), !is.na(Storage_pct)) |>
  arrange(Date) |>
  distinct(Date, .keep_all = TRUE)

  span_days <- as.numeric(max(storage$Date) - min(storage$Date))
  cat("Storage:", nrow(storage), "obs. od", as.character(min(storage$Date)),
      "do", as.character(max(storage$Date)),
      "(plik:", basename(storage_path), ")\n")

  if (span_days < 365) {
    warning("Plik storage pokrywa tylko ", span_days, " dni - za mało dla modelu.\n",
            "Wroc na https://agsi.gie.eu/data-overview/EU, ustaw zakres dat\n",
            "od 2015-01-01 do 2024-11-29 i pobierz ponownie.")
  }
} else {
  storage <- NULL
  warning("Brak pliku storage w ", RAW_DIR,
          " - pobierz z https://agsi.gie.eu/data-overview/EU.")
}

```

## Storage: 3616 obs. od 2015-01-01 do 2024-11-24 (plik: StorageData\_GIE\_2015-01-01\_2024-11-24.csv )

### 3.6 TTF (Kaggle / Investing.com)

```

ttf <- read_csv(file.path(RAW_DIR, "ttf.csv"), show_col_types = FALSE) |>
  mutate(
    Date = as.Date(parse_date_time(Date, orders = c("dmy", "mdy", "ymd"))),
    Price = as.numeric(gsub(",", "", as.character(Price)))
  ) |>
  select(Date, TTF = Price) |>
  filter(!is.na(Date), !is.na(TTF)) |>
  arrange(Date) |>
  distinct(Date, .keep_all = TRUE)

cat("TTF      :", nrow(ttf), "obs. (",
    as.character(min(ttf$Date)), "-", as.character(max(ttf$Date)), ")\n")

```

```
## TTF      : 1790 obs. ( 2017-10-23 - 2024-11-29 )
```

### 3.7 Scalenie i raport jakości

Łączymy po kalendarzu TTF (sesje giełdowe). Krótkie luki (weekendy, święta) uzupełniamy LOCF z limitem 5 dni.

```
df <- ttf |>
  left_join(brent |> select(Date, Brent), by = "Date") |>
  left_join(eurusd |> select(Date, EURUSD), by = "Date")

if (!is.null(storage)) {
  df <- df |> left_join(storage |> select(Date, Storage_pct), by = "Date")
}
if (!is.null(weather)) {
  df <- df |> left_join(weather |> select(Date, T_mean_EU, HDD), by = "Date")
}

locf_cols <- intersect(c("Brent", "EURUSD", "Storage_pct", "T_mean_EU", "HDD"),
  names(df))
df <- df |>
  mutate(across(all_of(locf_cols), ~ zoo::na.locf(.x, maxgap = 5, na.rm = FALSE)))

# Zostawiamy tylko wiersze z kompletem zmiennych dziennych
core_cols <- intersect(c("TTF", "Brent", "EURUSD"), names(df))
df <- df |> filter(if_all(all_of(core_cols), ~ !is.na(.x)))

quality <- df |>
  summarise(across(everything(), ~ sum(is.na(.x)))) |>
  pivot_longer(everything(), names_to = "Zmienna", values_to = "NA_count") |>
  mutate(NA_pct = round(100 * NA_count / nrow(df), 2)) |>
  filter(Zmienna != "Date")

kable(quality, caption = "Braki danych w finalnym panelu", booktabs = TRUE) |>
  kable_styling(latex_options = c("striped", "HOLD_position"), full_width = FALSE)
```

Tabela 1: Braki danych w finalnym panelu

| Zmienna     | NA_count | NA_pct |
|-------------|----------|--------|
| TTF         | 0        | 0      |
| Brent       | 0        | 0      |
| EURUSD      | 0        | 0      |
| Storage_pct | 0        | 0      |
| T_mean_EU   | 0        | 0      |
| HDD         | 0        | 0      |

```
write_csv(df, file.path(PROC_DIR, "ttf_merged.csv"))

cat("\nFinalny panel:", nrow(df), "obs.",
  as.character(min(df$Date)), "-", as.character(max(df$Date)), "\n")
```

```
##
## Finalny panel: 1790 obs., 2017-10-23 - 2024-11-29
```

### 3.8 Statystyki opisowe

```
num_cols <- df |> select(where(is.numeric)) |> names()

stats <- df |>
  select(all_of(num_cols)) |>
  summarise(across(everything(), list(
    Srednia = ~ mean(.x, na.rm = TRUE),
    Mediana = ~ median(.x, na.rm = TRUE),
    Odch_std = ~ sd(.x, na.rm = TRUE),
    Min = ~ min(.x, na.rm = TRUE),
    Max = ~ max(.x, na.rm = TRUE),
    Skosnosc = ~ moments::skewness(.x, na.rm = TRUE),
    Kurtoza = ~ moments::kurtosis(.x, na.rm = TRUE)
  ))) |>
  pivot_longer(everything(),
    names_to = c("Zmienna", ".value"),
    names_sep = "_(?=[A-Z][a-z])")

kable(stats, digits = 2, caption = "Statystyki opisowe", booktabs = TRUE) |>
  kable_styling(latex_options = c("striped", "HOLD_position"))
```

Tabela 2: Statystyki opisowe

| Zmienna     | Srednia | Mediana | Odch_std | Min   | Max    | Skosnosc | Kurtoza |
|-------------|---------|---------|----------|-------|--------|----------|---------|
| TTF         | 42.62   | 26.01   | 45.43    | 3.51  | 339.20 | 2.43     | 9.73    |
| Brent       | 72.79   | 73.72   | 18.89    | 9.12  | 133.18 | -0.12    | 4.00    |
| EURUSD      | 1.12    | 1.12    | 0.06     | 0.96  | 1.25   | -0.03    | 2.67    |
| Storage_pct | 68.25   | 70.88   | 21.27    | 17.75 | 99.50  | -0.48    | 2.22    |
| T_mean_EU   | 11.98   | 11.45   | 6.56     | -4.74 | 29.81  | 0.07     | 2.14    |
| HDD         | 6.67    | 6.55    | 5.65     | 0.00  | 22.75  | 0.32     | 1.97    |

## 4 Analiza eksploracyjna (EDA)


### 4.1 Wykresy szeregów

```
df |>
  pivot_longer(-Date, names_to = "Zmienna", values_to = "Wartosc") |>
  ggplot(aes(Date, Wartosc, color = Zmienna)) +
  geom_line(linewidth = 0.5, show.legend = FALSE) +
  facet_wrap(~ Zmienna, scales = "free_y", ncol = 1) +
  geom_vline(xintercept = as.Date("2022-02-24"),
    linetype = "dashed", color = "red", alpha = 0.6) +
  labs(title = "Szeregi czasowe: TTF i regresory fundamentalne",
```

```
subtitle = "Czerwona linia: inwazja Rosji na Ukrainie (24.02.2022)",  
x = NULL, y = NULL) +  
theme(strip.text = element_text(face = "bold"))
```

## Szeregi czasowe: TTF i regresory fundamentalne

Czerwona linia: inwazja Rosji na Ukrainę (24.02.2022)



Rysunek 2: Ewolucja wszystkich analizowanych szeregów

## Obserwacje:

- **TTF**: do końca 2020 r. cena oscyluje w okolicach 10–25 EUR/MWh. Od jesieni 2021 silny wzrost (kryzys energetyczny), kulminacja w sierpniu 2022 (powyżej 300 EUR/MWh), następnie powolna normalizacja do poziomu ~30–50 EUR/MWh w 2024 r.
- **Brent**: wyraźna ko-ewolucja z TTF w okresie kryzysu (2022), choć szok TTF jest proporcjonalnie znacznie silniejszy (specyfika rynku gazu vs. ropy).
- **EUR/USD**: trend deprecjacyjny euro od 2021 r. (osiągnięcie parytetu w 2022), częściowe odbicie w 2023. Dolar mocny → droższy LNG dla Europy → presja na TTF.
- **Storage\_pct**: wyraźny cykl roczny (latem napełnianie, zimą wycofywanie). W 2022 r. UE wymusiła administracyjnie wysokie poziomy zapasów (rozporządzenie REPowerEU, cel 80%/90%) — widoczne podwyższenie minimów cyklu.

## 4.2 Log-stopyy zwrotu i pierwsze różnice


```
has_storage <- "Storage_pct" %in% names(df)
has_hdd      <- "HDD"        %in% names(df)

df_diff <- df |>
  mutate(
    r_TTF      = c(NA, diff(log(TTF))),
    r_Brent    = c(NA, diff(log(Brent))),
    r_EURUSD   = c(NA, diff(log(EURUSD))),
    d_Storage  = if (has_storage) c(NA, diff(Storage_pct)) else NA_real_,
    d_HDD      = if (has_hdd)      c(NA, diff(HDD))          else NA_real_
  ) |>
  filter(if_all(c(r_TTF, r_Brent, r_EURUSD), ~ !is.na(.x)))

returns <- df_diff$r_TTF
```

```
ggplot(df_diff, aes(Date, r_TTF)) +
  geom_line(color = "darkred", linewidth = 0.4) +
  labs(title = "Log-stopyy zwrotu TTF", x = NULL, y = expression(r[t]))
```





Rysunek 3: Logarytmiczne stopy zwrotu TTF — widoczne klastry zmienności

**Klastrowanie zmienności** widoczne na wykresie jest cechą charakterystyczną szeregów finansowych: okresy spokojne (małe wahania) przeplatają się z okresami turbulencji (duże skoki). W 2018–2020 amplituda dziennych zmian rzadko przekracza  $\pm 5\%$ , natomiast w okresie 2021–2023 codziennie pojawiają się ruchy rzędu  $\pm 20\%$  lub więcej. To uzasadnia modelowanie *warunkowej* wariancji (GARCH-rodzina) zamiast założenia stałej zmienności.

```
ret_stats <- tibble(
  Srednia      = mean(returns),
  Odch_std     = sd(returns),
  Min          = min(returns),
  Max          = max(returns),
  Skosnosc     = moments::skewness(returns),
  Kurtoza_nadwyzkowa = moments::kurtosis(returns) - 3,
  JB_pvalue    = jarque.bera.test(returns)$p.value
)

kable(ret_stats, digits = 4, caption = "Statystyki log-stop zwrotu TTF",
      booktabs = TRUE)
```

Tabela 3: Statystyki log-stop zwrotu TTF

| Srednia | Odch_std | Min     | Max    | Skosnosc | Kurtoza_nadwyzkowa | JB_pvalue |
|---------|----------|---------|--------|----------|--------------------|-----------|
| 5e-04   | 0.0526   | -0.3524 | 0.4128 | 0.378    | 7.5557             | 0         |

## 4.3 Korelacje

```
cor_levels <- df |> select(all_of(num_cols)) |> cor(use = "pairwise.complete.obs")

ret_cols <- intersect(c("r_TTF", "r_Brent", "r_EURUSD", "d_Storage", "d_HDD"),
                     names(df_diff))
cor_diffs <- df_diff |> select(all_of(ret_cols)) |>
  cor(use = "pairwise.complete.obs")

kable(round(cor_levels, 3),
      caption = "Korelacje w poziomach (uwaga: szeregi I(1), mozliwe pozorne)",
      booktabs = TRUE)
```

Tabela 4: Korelacje w poziomach (uwaga: szeregi I(1), mozliwe pozorne)

|             | TTF    | Brent  | EURUSD | Storage_pct | T_mean_EU | HDD    |
|-------------|--------|--------|--------|-------------|-----------|--------|
| TTF         | 1.000  | 0.651  | -0.549 | -0.002      | 0.076     | -0.056 |
| Brent       | 0.651  | 1.000  | -0.460 | -0.157      | 0.115     | -0.112 |
| EURUSD      | -0.549 | -0.460 | 1.000  | -0.377      | -0.149    | 0.154  |
| Storage_pct | -0.002 | -0.157 | -0.377 | 1.000       | 0.168     | -0.168 |
| T_mean_EU   | 0.076  | 0.115  | -0.149 | 0.168       | 1.000     | -0.978 |
| HDD         | -0.056 | -0.112 | 0.154  | -0.168      | -0.978    | 1.000  |

```
kable(round(cor_diffs, 3),
      caption = "Korelacje stop zwrotu / pierwszych roznic (krotkookresowe)",
      booktabs = TRUE)
```

Tabela 5: Korelacje stop zwrotu / pierwszych roznic (krotkookresowe)

|           | r_TTF  | r_Brent | r_EURUSD | d_Storage | d_HDD  |
|-----------|--------|---------|----------|-----------|--------|
| r_TTF     | 1.000  | 0.115   | -0.107   | 0.052     | 0.038  |
| r_Brent   | 0.115  | 1.000   | 0.011    | -0.006    | 0.015  |
| r_EURUSD  | -0.107 | 0.011   | 1.000    | -0.007    | -0.011 |
| d_Storage | 0.052  | -0.006  | -0.007   | 1.000     | -0.018 |
| d_HDD     | 0.038  | 0.015   | -0.011   | -0.018    | 1.000  |

## 5 Testy stacjonarności

$H_0$  (ADF): szereg jest niestacjonarny.  $H_0$  (KPSS): szereg jest stacjonarny.

```
do_tests <- function(x, name) {
  x <- na.omit(x)
  adf <- suppressWarnings(adf.test(x))
  kpss <- suppressWarnings(kpss.test(x))
  tibble(
    Zmienna = name,
```

```

    ADF_stat = round(adf$statistic, 3),
    ADF_pvalue = round(adf$p.value, 3),
    KPSS_stat = round(kpss$statistic, 3),
    KPSS_pvalue = round(kpss$p.value, 3)
  )
}

vars_levels <- list(
  "log(TTF)" = log(df$TTF),
  "log(Brent)" = log(df$Brent),
  "log(EURUSD)" = log(df$EURUSD)
)
if (has_hdd) vars_levels[["HDD"]] <- df$HDD
if (has_storage) vars_levels[["Storage_pct"]] <- df$Storage_pct

vars_diffs <- list(
  "d log(TTF)" = df_diff$r_TTF,
  "d log(Brent)" = df_diff$r_Brent,
  "d log(EURUSD)" = df_diff$r_EURUSD
)
if (has_hdd) vars_diffs[["d HDD"]] <- df_diff$d_HDD
if (has_storage) vars_diffs[["d Storage_pct"]] <- df_diff$d_Storage

levels_tests <- imap_dfr(vars_levels, ~ do_tests(.x, .y))
diffs_tests <- imap_dfr(vars_diffs, ~ do_tests(.x, .y))

kable(levels_tests, caption = "Stacjonarnosc - poziomy", booktabs = TRUE) |>
  kable_styling(latex_options = c("striped", "HOLD_position"))

```

Tabela 6: Stacjonarnosc - poziomy

| Zmienna     | ADF_stat | ADF_pvalue | KPSS_stat | KPSS_pvalue |
|-------------|----------|------------|-----------|-------------|
| log(TTF)    | -1.398   | 0.833      | 7.953     | 0.01        |
| log(Brent)  | -2.276   | 0.462      | 5.526     | 0.01        |
| log(EURUSD) | -2.025   | 0.568      | 7.925     | 0.01        |
| HDD         | -2.901   | 0.197      | 0.330     | 0.10        |
| Storage_pct | -6.128   | 0.010      | 1.681     | 0.01        |

```

kable(diffs_tests, caption = "Stacjonarnosc - pierwsze roznice", booktabs = TRUE) |>
  kable_styling(latex_options = c("striped", "HOLD_position"))

```

Tabela 7: Stacjonarnosc - pierwsze roznice

| Zmienna       | ADF_stat | ADF_pvalue | KPSS_stat | KPSS_pvalue |
|---------------|----------|------------|-----------|-------------|
| d log(TTF)    | -12.565  | 0.010      | 0.116     | 0.1         |
| d log(Brent)  | -11.032  | 0.010      | 0.049     | 0.1         |
| d log(EURUSD) | -12.414  | 0.010      | 0.052     | 0.1         |
| d HDD         | -16.156  | 0.010      | 0.018     | 0.1         |
| d Storage_pct | -3.635   | 0.029      | 0.233     | 0.1         |

**Wniosek:** szeregi cenowe są  $I(1)$ , pierwsze różnice stacjonarne — **H1 potwierdzona**.

## 6 Selekcja zmiennych objaśniających

Mając już *a priori* uzasadnienie ekonomiczne (sekcja 3.2 — *Uzasadnienie ekonomiczne wyboru zmiennych*) i potwierdzony rząd integracji szeregów (sekcja 5 — wszystkie ceny I(1), pierwsze różnice I(0)), zanim przejdziemy do modelowania wykonujemy formalną statystyczną selekcję regresorów. Cel: ustalić, które z czterech kandydatów ( $\log(\text{Brent})$ ,  $\log(\text{EURUSD})$ ,  $\text{Storage\_pct}$ ,  $\text{HDD}$ ) faktycznie wnoszą informację o cenie TTF i nie wprowadzają patologii (silna współliniowość).

### 6.1 Metodologia selekcji

W docelowym modelu ARIMAX(p, 1, q) regresory wchodzą w **poziomach**, ale ze względu na różnicowanie zmiennej zależnej  $\log TTF_t$  równanie efektywnie opisuje krótkookresowe relacje między **pierwszymi różnicami**. Dlatego selekcji dokonujemy na pomocniczej regresji statycznej w pierwszych różnicach:

$$\Delta \log TTF_t = \alpha + \beta_1 \Delta \log \text{Brent}_t + \beta_2 \Delta \log \text{EURUSD}_t + \beta_3 \Delta \text{Storage}_t + \beta_4 \Delta \text{HDD}_t + u_t$$

Zalety tego podejścia:

- regresory są I(0) (potwierdzone testami ADF/KPSS w sekcji 5) → t-statystyki OLS są **statystycznie poprawne** (brak ryzyka *spurious regression* obecnego w regresji w poziomach);
- procedura jest niezależna od późniejszego doboru rzędów ARMA — selekcja regresorów odbywa się przed identyfikacją dynamiki, zgodnie z dobrą praktyką *general-to-specific* (Hendry);
- VIF policzony na regresorach w różnicach jest miarą współliniowości szoków, nie poziomów, ale w przypadku regresorów I(1) jest to *jedyna* sensowna interpretacja (VIF na poziomach byłby zdominowany przez wspólny trend).

Procedura w czterech krokach: (1) test współliniowości VIF, (2) ocena istotności regresorów testem t, (3) eliminacja wsteczna (próg  $p > 0.10$ ), (4) porównanie modeli zagnieżdżonych kryteriami AIC/BIC.

### 6.2 Krok 1 — Test współliniowości (VIF)

```
ols_vars <- c("r_Brent", "r_EURUSD")
if (has_storage) ols_vars <- c(ols_vars, "d_Storage")
if (has_hdd)      ols_vars <- c(ols_vars, "d_HDD")

ols_data <- df_diff |>
  select(r_TTF, all_of(ols_vars)) |>
  drop_na()

cat("Liczba obserwacji w regresji selekcyjnej:", nrow(ols_data), "\n")
```

```
## Liczba obserwacji w regresji selekcyjnej: 1789
```

```
cat("Regresory testowane:", paste(ols_vars, collapse = ", "), "\n\n")
```

```
## Regresory testowane: r_Brent, r_EURUSD, d_Storage, d_HDD
```

```

ols_full <- lm(reformulate(ols_vars, "r_TTF"), data = ols_data)

vif_manual <- function(X) {
  X <- as.matrix(X)
  k <- ncol(X)
  vifs <- numeric(k)
  for (i in seq_len(k)) {
    r2 <- summary(lm(X[, i] ~ X[, -i]))$r.squared
    vifs[i] <- 1 / (1 - r2)
  }
  setNames(vifs, colnames(X))
}

ols_X <- as.matrix(ols_data[, ols_vars])
vif_values <- vif_manual(ols_X)

vif_df <- tibble(
  Regresor = names(vif_values),
  VIF       = round(vif_values, 2),
  Diagnoza  = case_when(
    vif_values > 10 ~ "silna wspolliniowosc",
    vif_values > 5  ~ "umiarkowana",
    TRUE           ~ "OK"
  )
)

kable(vif_df,
      caption = "Wspolczynniki inflacji wariancji (VIF) regresorow w pierwszych roznicach",
      booktabs = TRUE) |>
kable_styling(latex_options = c("striped", "HOLD_position"), full_width = FALSE)

```

Tabela 8: Wspolczynniki inflacji wariancji (VIF) regresorow w pierwszych roznicach

| Regresor  | VIF | Diagnoza |
|-----------|-----|----------|
| r_Brent   | 1   | OK       |
| r_EURUSD  | 1   | OK       |
| d_Storage | 1   | OK       |
| d_HDD     | 1   | OK       |

**Reguła kciuka:**  $VIF < 5$  — brak problemu,  $5 \leq VIF < 10$  — umiarkowana współliniowość (akceptowalna),  $VIF \geq 10$  — silna współliniowość (sygnał do usunięcia regresora). Definicja:  $VIF_j = 1/(1 - R_j^2)$ , gdzie  $R_j^2$  to współczynnik determinacji pomocniczej regresji  $X_j$  na pozostałych regresorach.

### 6.3 Krok 2 — Istotność regresorów (test t)

```

ols_summary <- summary(ols_full)
coef_table <- ols_summary$coefficients

```

```
sig_table <- tibble(
  Regresor = rownames(coef_table)[-1],
  Wsp      = round(coef_table[-1, "Estimate"], 5),
  SE       = round(coef_table[-1, "Std. Error"], 5),
  t        = round(coef_table[-1, "t value"], 2),
  p_value  = round(coef_table[-1, "Pr(>|t|)"], 4),
  Istotny  = ifelse(coef_table[-1, "Pr(>|t|)"] < 0.05, "TAK", "nie")
)

kable(sig_table,
  caption = "Istotnosc regresorow w statycznej regresji OLS (pierwsze roznice)",
  booktabs = TRUE) |>
  kable_styling(latex_options = c("striped", "HOLD_position"), full_width = FALSE)
```

Tabela 9: Istotnosc regresorow w statycznej regresji OLS (pierwsze roznice)

| Regresor  | Wsp      | SE      | t     | p_value | Istotny |
|-----------|----------|---------|-------|---------|---------|
| r_Brent   | 0.18032  | 0.03631 | 4.97  | 0.0000  | TAK     |
| r_EURUSD  | -1.28697 | 0.27923 | -4.61 | 0.0000  | TAK     |
| d_Storage | 0.00476  | 0.00209 | 2.28  | 0.0230  | TAK     |
| d_HDD     | 0.00114  | 0.00075 | 1.52  | 0.1282  | nie     |

```
cat("R^2 pelnego OLS:", round(ols_summary$r.squared, 4),
    "\nF-statystyka :", round(ols_summary$fstatistic[1], 2),
    "\np-value F      :", format.pval(pf(ols_summary$fstatistic[1],
                                         ols_summary$fstatistic[2],
                                         ols_summary$fstatistic[3],
                                         lower.tail = FALSE)), "\n")
```

```
## R^2 pelnego OLS: 0.0289
## F-statystyka : 13.29
## p-value F      : 1.1256e-10
```

## 6.4 Krok 3 — Eliminacja wsteczna (general-to-specific)

W każdej iteracji usuwamy regresor o najwyższym  $p$ -value powyżej 0.10, ponownie estymujemy OLS i powtarzamy aż wszystkie pozostałe regresory są istotne.

```
current_vars <- ols_vars
fit_current <- ols_full

elimination_log <- tibble(
  Krok      = integer(),
  Eliminowana = character(),
  p_value   = numeric(),
  R2_po     = numeric(),
  AIC_po    = numeric(),
  BIC_po    = numeric(),
  Pozostale = character())
```

```

)
step <- 0

repeat {
  cf_table <- summary(fit_current)$coefficients
  pv_regs <- cf_table[current_vars, "Pr(>|t|)"]
  pv_regs <- pv_regs[!is.na(pv_regs)]

  if (length(pv_regs) == 0 || max(pv_regs) < 0.10) break

  drop_var <- names(which.max(pv_regs))
  max_p <- unname(max(pv_regs))
  current_vars <- setdiff(current_vars, drop_var)

  fit_current <- if (length(current_vars) == 0) {
    lm(r_TTF ~ 1, data = ols_data)
  } else {
    lm(reformulate(current_vars, "r_TTF"), data = ols_data)
  }

  step <- step + 1
  elimination_log <- bind_rows(elimination_log, tibble(
    Krok = step,
    Eliminowana = drop_var,
    p_value = round(max_p, 4),
    R2_po = round(summary(fit_current)$r.squared, 4),
    AIC_po = round(AIC(fit_current), 2),
    BIC_po = round(BIC(fit_current), 2),
    Pozostale = if (length(current_vars)) paste(current_vars, collapse = ", ") else "(brak)"
  ))
}

if (nrow(elimination_log) == 0) {
  cat("Wszystkie regresory istotne na poziomie 0.10 - eliminacja nie usuwa zadnego.\n")
} else {
  kable(elimination_log,
    caption = "Przebieg eliminacji wstecznej (prog usuniecia: p > 0.10)",
    booktabs = TRUE) |>
  kable_styling(latex_options = c("striped", "HOLD_position"), full_width = FALSE)
}

```

Tabela 10: Przebieg eliminacji wstecznej (prog usuniecia:  $p > 0.10$ )

| Krok | Eliminowana | p_value | R2_po  | AIC_po   | BIC_po   | Pozostale                    |
|------|-------------|---------|--------|----------|----------|------------------------------|
| 1    | d_HDD       | 0.1282  | 0.0277 | -5500.52 | -5473.07 | r_Brent, r_EURUSD, d_Storage |

```

selected_diff_vars <- current_vars

cat("\nFinalny zbior regresorow (w pierwszych roznicach):\n ",
  if (length(selected_diff_vars)) paste(selected_diff_vars, collapse = ", ") else "(zaden)",
  "\n")

```

```
##
## Finalny zbior regresorow (w pierwszych roznicach):
##   r_Brent, r_EURUSD, d_Storage
```

## 6.5 Krok 4 — Porównanie modeli zagnieżdżonych (AIC / BIC)

Sprawdzamy systematycznie sensowne podzbiory regresorów — pełny, wynik eliminacji wstecznej oraz warianty teoretyczne (tylko Brent jako “kotwica cenowa”, same regresory popytowe itd.).

```
build_ols <- function(vars) {
  if (length(vars) == 0) {
    lm(r_TTF ~ 1, data = ols_data)
  } else {
    lm(reformulate(vars, "r_TTF"), data = ols_data)
  }
}

candidates <- list(
  "Pełny (wszystkie regresory)" = ols_vars,
  "Bez d_HDD"                  = setdiff(ols_vars, "d_HDD"),
  "Bez d_Storage"              = setdiff(ols_vars, "d_Storage"),
  "Tylko Brent + EURUSD"       = intersect(ols_vars, c("r_Brent", "r_EURUSD")),
  "Tylko Brent"                = intersect(ols_vars, "r_Brent"),
  "Po eliminacji wstecznej"    = selected_diff_vars,
  "Sama stała"                 = character(0)
)

candidates <- candidates[!duplicated(lapply(candidates, function(x) sort(as.character(x))))]

nested_table <- imap_dfr(candidates, function(vars, name) {
  m <- tryCatch(build_ols(vars), error = function(e) NULL)
  if (is.null(m)) return(tibble())
  s <- summary(m)
  tibble(
    Wariant    = name,
    Regresory  = if (length(vars)) paste(vars, collapse = ", ") else "(brak)",
    k          = length(vars),
    R2_adj     = round(s$adj.r.squared, 4),
    AIC        = round(AIC(m), 2),
    BIC        = round(BIC(m), 2)
  )
}) |> arrange(BIC)

kable(nested_table,
  caption = "Porównanie zagnieżdżonych wariantów OLS w różnicach (sortowane po BIC)",
  booktabs = TRUE) |>
  kable_styling(latex_options = c("striped", "HOLD_position"))
```

Tabela 11: Porównanie zagnieżdżonych wariantów OLS w różnicach (sortowane po BIC)

| Wariant              | Regresory         | k | R2_adj | AIC      | BIC      |
|----------------------|-------------------|---|--------|----------|----------|
| Tylko Brent + EURUSD | r_Brent, r_EURUSD | 2 | 0.0238 | -5497.46 | -5475.51 |



|                             |                                     |   |        |          |          |
|-----------------------------|-------------------------------------|---|--------|----------|----------|
| Bez d_HDD                   | r_Brent, r_EURUSD, d_Storage        | 3 | 0.0260 | -5500.52 | -5473.07 |
| Bez d_Storage               | r_Brent, r_EURUSD, d_HDD            | 3 | 0.0245 | -5497.65 | -5470.21 |
| Pełny (wszystkie regresory) | r_Brent, r_EURUSD, d_Storage, d_HDD | 4 | 0.0268 | -5500.84 | -5467.90 |
| Tylko Brent                 | r_Brent                             | 1 | 0.0126 | -5478.06 | -5461.59 |
| Sama stała                  | (brak)                              | 0 | 0.0000 | -5456.30 | -5445.32 |

## 6.6 Wnioski z procedury selekcji

Selekcja zmiennych łączy trzy niezależne kryteria:

1. **A priori ekonomiczne** (sekcja 3.2) — każda z 4 zmiennych ma uzasadniony mechanizm rynkowy.
2. **Test t Walda na regresorach** w statycznej regresji OLS (różnice) — zachowujemy regresory istotne na poziomie 0.05–0.10.
3. **Eliminacja wsteczna + porównanie zagnieżdżone po BIC** — produkujemy minimalny zbiór regresorów istotnych statystycznie i sprawdzamy, czy parsymonijny model nie wypada lepiej informacyjnie od pełnego.

```
var_mapping <- c(
  r_Brent = "log_Brent",
  r_EURUSD = "log_EURUSD",
  d_Storage = "Storage_pct",
  d_HDD = "HDD"
)

selected_arimax_vars <- unname(var_mapping[selected_diff_vars])

cat("Wybrane regresory (mapowanie na wersje w poziomach dla ARIMAX):\n")
```

```
## Wybrane regresory (mapowanie na wersje w poziomach dla ARIMAX):
```

```
for (v in selected_diff_vars) {
  cat(" ", v, " -> ", var_mapping[[v]], "\n", sep = "")
}
```

```
## r_Brent -> log_Brent
## r_EURUSD -> log_EURUSD
## d_Storage -> Storage_pct
```

```
cat("\nOdrzucone regresory:\n ",
    paste(setdiff(ols_vars, selected_diff_vars), collapse = ", "), "\n")
```

```
##
## Odrzucone regresory:
## d_HDD
```

**Mapowanie różnice → poziomy:** w pomocniczej regresji selekcyjnej operowaliśmy na różnicach (r\_Brent, r\_EURUSD, d\_Storage, d\_HDD), które są bezpośrednio proporcjonalne do regresorów w poziomach używanych w ARIMAX (log\_Brent, log\_EURUSD, Storage\_pct, HDD). Decyzja o usunięciu regresora w wersji różnicowej automatycznie usuwa jego odpowiednik w wersji poziomej.

W dalszej części analizy szacujemy **dwa modele ARIMAX**:

- **ARIMAX pełny** — z wszystkimi 4 regresorami (model referencyjny, *general unrestricted model*);
- **ARIMAX po selekcji** — tylko z wybranymi regresorami (model docelowy, używany w prognozach i porównaniach OOS).

## 7 Analiza kointegracji

### 7.1 Engle-Granger (TTF vs Brent)

Procedura dwuetapowa: (1) regresja statyczna  $\log TTF_t = \alpha + \beta \log Brent_t + u_t$ , (2) test stacjonarności reszt  $\hat{u}_t$ .

```
eg_reg <- lm(log(TTF) ~ log(Brent), data = df)
summary(eg_reg)

##
## Call:
## lm(formula = log(TTF) ~ log(Brent), data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.0231 -0.3948 -0.1126  0.2857  2.8073
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -5.65580    0.17778  -31.81  <2e-16 ***
## log(Brent)   2.12238    0.04176   50.83  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5481 on 1788 degrees of freedom
## Multiple R-squared:  0.591, Adjusted R-squared:  0.5908
## F-statistic: 2584 on 1 and 1788 DF, p-value: < 2.2e-16

adf_eg <- adf.test(residuals(eg_reg))
print(adf_eg)

##
## Augmented Dickey-Fuller Test
##
## data: residuals(eg_reg)
## Dickey-Fuller = -3.3012, Lag order = 12, p-value = 0.07046
## alternative hypothesis: stationary
```

**Uwaga metodologiczna:** standardowy test ADF na resztach regresji kointegrującej używa *niewłaściwych* wartości krytycznych — odrzucenie  $H_0$  wymaga bardziej restrykcyjnych progów (Phillips-Ouliaris, MacKinnon). Poniżej formalnie poprawna wersja.

### 7.2 Phillips-Ouliaris

Test wprost zaprojektowany dla relacji kointegrującej, używa właściwych wartości krytycznych.

```
po_data <- cbind(log(df$TTF), log(df$Brent))
po_test <- ca.po(po_data, type = "Pz", demean = "constant")
summary(po_test)
```

```
##
## #####
## # Phillips and Ouliaris Unit Root Test #
## #####
##
## Test of type Pz
## detrending of series with constant only
##
## Response Y1 :
##
## Call:
## lm(formula = Y1 ~ zr)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.34931 -0.02617 -0.00048  0.02216  0.41389
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.035781   0.021334  -1.677   0.0937 .
## zr1          0.994548   0.002268 438.498 <2e-16 ***
## zr2          0.012863   0.006261   2.054   0.0401 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.05256 on 1786 degrees of freedom
## Multiple R-squared:  0.9962, Adjusted R-squared:  0.9962
## F-statistic: 2.368e+05 on 2 and 1786 DF, p-value: < 2.2e-16
##
##
## Response Y2 :
##
## Call:
## lm(formula = Y2 ~ zr)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.65655 -0.01125  0.00166  0.01354  0.39147
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.042144   0.013696   3.077  0.00212 **
## zr1          0.002901   0.001456   1.993  0.04645 *
## zr2          0.987815   0.004020 245.755 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.03374 on 1786 degrees of freedom
## Multiple R-squared:  0.9882, Adjusted R-squared:  0.9882
```

```
## F-statistic: 7.476e+04 on 2 and 1786 DF, p-value: < 2.2e-16
##
##
## Value of test-statistic is: 12.4892
##
## Critical values of Pz are:
##          10pct    5pct    1pct
## critical values 47.5877 55.2202 71.9273
```

$H_0$ : brak kointegracji. Jeśli statystyka testu *przekracza* wartość krytyczną (np. dla 5%) — odrzucamy  $H_0$  → istnieje kointegracja. W przeciwnym razie nie ma podstaw do budowy modelu długookresowej równowagi (VECM).

### 7.3 Johansen (TTF, Brent, EUR/USD)

```
johansen_data <- df |>
  transmute(log_TTF = log(TTF), log_Brent = log(Brent), log_EURUSD = log(EURUSD)) |>
  as.matrix()

joh <- ca.jo(johansen_data, type = "trace", ecdet = "const", K = 2)
summary(joh)
```

```
##
## #####
## # Johansen-Procedure #
## #####
##
## Test type: trace statistic , without linear trend and constant in cointegration
##
## Eigenvalues (lambda):
## [1] 0.008857632 0.006632453 0.002304946 0.000000000
##
## Values of teststatistic and critical values of test:
##
##          test 10pct  5pct  1pct
## r <= 2 |   4.13   7.52   9.24 12.97
## r <= 1 |  16.02  17.85  19.96 24.60
## r = 0  |  31.93  32.00  34.91 41.07
##
## Eigenvectors, normalised to first column:
## (These are the cointegration relations)
##
##          log_TTF.12 log_Brent.12 log_EURUSD.12    constant
## log_TTF.12      1.000000      1.000000      1.000000      1.000000
## log_Brent.12   -4.590779     -1.636728      0.8746197    0.5691903
## log_EURUSD.12 -10.933589     12.689853     -5.0355828   40.2169208
## constant      17.274988      2.244967     -6.5346977  -19.5085140
##
## Weights W:
## (This is the loading matrix)
```


```
##
##               log_TTF.12  log_Brent.12  log_EURUSD.12      constant
## log_TTF.d      -0.0032931543  0.0006429902 -1.456689e-03  6.938349e-20
## log_Brent.d    0.0015535325  0.0026136788 -7.746046e-04 -7.626163e-19
## log_EURUSD.d   0.0001863115 -0.0004147812 -7.409509e-05 -8.899601e-20
```

**Jak czytać:** testujemy sekwencyjnie  $H_0 : r = 0, r \leq 1, r \leq 2$ . Najmniejsze  $r$ , dla którego *nie odrzucamy*  $H_0$  — liczba wektorów kointegrujących.

**Interpretacja wyników** (do uzupełnienia po knit-cie): jeśli statystyka dla  $r = 0$  nie przekracza wartości krytycznej 5% → **brak kointegracji**, nawet jeśli wynik jest blisko granicy. W naszym wypadku (31.93 vs 34.91) Johansen *nie odrzuca* braku kointegracji na poziomie 5%. **H2 odrzucona** lub co najwyżej marginalna.

## 8 Identyfikacja ARIMA

```
par(mfrow = c(2, 1))
acf(returns, main = "ACF: r_TTF", lag.max = 40)
pacf(returns, main = "PACF: r_TTF", lag.max = 40)
```



Rysunek 4: ACF i PACF log-stop zwrotu TTF

```
par(mfrow = c(1, 1))
```

#### Wnioski z ACF/PACF:

- ACF i PACF szybko opadają do zera od pierwszego opóźnienia, z pojedynczymi istotnymi opóźnieniami (rzędu 1–5) ledwo przekraczającymi przedział ufności ( $\pm 1.96/\sqrt{T}$ ).
- Brak wyraźnego “tail-off” / “cut-off” — szereg jest bliski białemu szumowi po zróżnicowaniu, co potwierdza stacjonarność log-stóp zwrotu.

- Wzorzec sugeruje proces AR niskiego rzędu z możliwymi krótkimi komponentami MA.
- Decyzję o ostatecznych rzędach  $(p, q)$  pozostawiamy procedurze `auto.arima` optymalizującej kryterium AICc — wynik to ARIMA(5, 1, 0).

## 9 Estymacja ARIMA i ARIMAX

### 9.1 Model bazowy: ARIMA jednowymiarowy

```
fit_arima <- auto.arima(
  log(df$TTF),
  d = 1, seasonal = FALSE,
  stepwise = FALSE, approximation = FALSE, ic = "aicc"
)
summary(fit_arima)
```

```
## Series: log(df$TTF)
## ARIMA(5,1,0)
##
## Coefficients:
##          ar1      ar2      ar3      ar4      ar5
##      0.0486 -0.0666 -0.0353  0.1160 -0.0529
## s.e.  0.0236  0.0235  0.0235  0.0234  0.0236
##
## sigma^2 = 0.00271:  log likelihood = 2751.22
## AIC=-5490.44  AICc=-5490.39  BIC=-5457.51
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.0005330637 0.05196973 0.03521682 0.002997964 1.074111 0.997455
##              ACF1
## Training set -0.0007983086
```

### 9.2 Model rozszerzony: ARIMAX

Wykorzystujemy wyniki sekcji 6 — *Selekcja zmiennych objaśniających*. Szacujemy **dwa modele**:

- **ARIMAX pełny** ze wszystkimi 4 kandydatami (model referencyjny, GUM); pozwala porównać AICc/BIC z modelem po selekcji i pokazać, czy odrzucenie zmiennych było uzasadnione informacyjnie;
- **ARIMAX po selekcji** — tylko z regresorami, które przeszły procedurę z sekcji 6 (model docelowy, używany w dalszej analizie OOS, w GARCH-X oraz w prognozie).

```
xreg_list <- list(
  log_Brent = log(df$Brent),
  log_EURUSD = log(df$EURUSD)
)
if (has_storage) xreg_list$Storage_pct <- df$Storage_pct
if (has_hdd) xreg_list$HDD <- df$HDD

xreg_full_all <- as.matrix(as.data.frame(xreg_list))
cat("Regresory w pełnym ARIMAX:", paste(colnames(xreg_full_all), collapse = ", "), "\n")
```

```
## Regresory w pelnym ARIMAX: log_Brent, log_EURUSD, Storage_pct, HDD
```

```
fit_arimax_full <- auto.arima(  
  log(df$TTF),  
  xreg = xreg_full_all,  
  d = 1, seasonal = FALSE,  
  stepwise = FALSE, approximation = FALSE, ic = "aicc"  
)  
cat("\n--- ARIMAX pelny (general unrestricted model) ---\n")
```

```
##  
## --- ARIMAX pelny (general unrestricted model) ---
```

```
summary(fit_arimax_full)
```

```
## Series: log(df$TTF)  
## Regression with ARIMA(5,1,0) errors  
##  
## Coefficients:  
##          ar1      ar2      ar3      ar4      ar5  log_Brent  log_EURUSD  
##      0.0427 -0.0713 -0.0415  0.1082 -0.0469    0.1711    -1.2558  
## s.e.  0.0237  0.0235  0.0236  0.0235  0.0237    0.0360    0.2739  
##      Storage_pct      HDD  
##           0.0048  1e-03  
## s.e.       0.0020  7e-04  
##  
## sigma^2 = 0.002641:  log likelihood = 2776.22  
## AIC=-5532.45  AICc=-5532.32  BIC=-5477.55  
##  
## Training set error measures:  
##              ME      RMSE      MAE      MPE      MAPE      MASE  
## Training set 0.0004366868 0.05124855 0.03494204 0.0007926701 1.071872 0.9896725  
##              ACF1  
## Training set -0.0006542292
```

```
if (exists("selected_arimax_vars") && length(selected_arimax_vars) > 0) {  
  xreg_sel <- xreg_full_all[, selected_arimax_vars, drop = FALSE]  
  fit_arimax_sel <- auto.arima(  
    log(df$TTF),  
    xreg = xreg_sel,  
    d = 1, seasonal = FALSE,  
    stepwise = FALSE, approximation = FALSE, ic = "aicc"  
  )  
  cat("\n--- ARIMAX po selekcji (model docelowy) ---\n")  
  cat("Regresory:", paste(selected_arimax_vars, collapse = ", "), "\n")  
  summary(fit_arimax_sel)  
  
  fit_arimax <- fit_arimax_sel  
  xreg_full <- xreg_sel  
} else {  
  warning("Selekcja wykluczyla wszystkie regresory - fallback do pelnego ARIMAX dla spojnosci downstream")  
  fit_arimax_sel <- fit_arimax_full
```



```

xreg_sel      <- xreg_full_all
fit_arimax    <- fit_arimax_full
xreg_full     <- xreg_full_all
}

##
## --- ARIMAX po selekcji (model docelowy) ---
## Regresory: log_Brent, log_EURUSD, Storage_pct

```

### 9.3 Porównanie ARIMA vs ARIMAX

```

cmp <- tibble(
  Model      = c("ARIMA(p,1,q)", "ARIMAX(p,1,q) - pelny", "ARIMAX(p,1,q) - po selekcji"),
  AICc       = c(fit_arima$aicc,      fit_arimax_full$aicc,  fit_arimax_sel$aicc),
  BIC        = c(fit_arima$bic,       fit_arimax_full$bic,  fit_arimax_sel$bic),
  log_Lik    = c(fit_arima$loglik,    fit_arimax_full$loglik, fit_arimax_sel$loglik),
  Liczba_par = c(length(fit_arima$coef), length(fit_arimax_full$coef),
                  length(fit_arimax_sel$coef))
)

kable(cmp, digits = 2,
      caption = "Porównanie modeli: ARIMA vs ARIMAX pelny vs ARIMAX po selekcji",
      booktabs = TRUE) |>
kable_styling(latex_options = c("striped", "HOLD_position"))

```

Tabela 12: Porównanie modeli: ARIMA vs ARIMAX pelny vs ARIMAX po selekcji

| Model                       | AICc     | BIC      | log_Lik | Liczba_par |
|-----------------------------|----------|----------|---------|------------|
| ARIMA(p,1,q)                | -5490.39 | -5457.51 | 2751.22 | 5          |
| ARIMAX(p,1,q) - pelny       | -5532.32 | -5477.55 | 2776.22 | 9          |
| ARIMAX(p,1,q) - po selekcji | -5532.41 | -5483.10 | 2775.25 | 8          |


Współczynniki na regresorach w “regresji z błędami ARIMA” interpretujemy jako długookresowe wrażliwości log-ceny TTF. Ujemny współczynnik przy `Storage_pct` potwierdza: wzrost zapasów o 1 p.p. obniża log-cenę TTF.

### 9.4 Diagnostyka reszt ARIMAX

```

arimax_resid <- residuals(fit_arimax)
checkresiduals(fit_arimax)

```



Rysunek 5: Diagnostyka reszt ARIMAX

```
##
##  Ljung-Box test
##
## data:  Residuals from Regression with ARIMA(5,1,0) errors
## Q* = 5.2203, df = 5, p-value = 0.3896
##
## Model df: 5.    Total lags used: 10
```

```
lb <- Box.test(arimax_resid, lag = 20, type = "Ljung-Box",
               fitdf = sum(fit_arimax$arma[1:2]))
print(lb)
```

```
##
##  Box-Ljung test
##
## data:  arimax_resid
## X-squared = 17.073, df = 15, p-value = 0.3145
```

```
jb <- jarque.bera.test(arimax_resid)
print(jb)
```

```
##
##  Jarque Bera Test
##
## data:  arimax_resid
## X-squared = 2894.3, df = 2, p-value < 2.2e-16
```


## 10 Test efektu ARCH

```
arch_test <- ArchTest(arimax_resid, lags = 12)
print(arch_test)
```


```
##
## ARCH LM-test; Null hypothesis: no ARCH effects
##
## data: arimax_resid
## Chi-squared = 285.53, df = 12, p-value < 2.2e-16
```

```
par(mfrow = c(2, 1))
acf(arimax_resid^2, main = "ACF kwadratów reszt", lag.max = 30)
pacf(arimax_resid^2, main = "PACF kwadratów reszt", lag.max = 30)
```

### ACF kwadratow reszt



### PACF kwadratow reszt



Rysunek 6: ACF i PACF kwadratow reszt ARIMAX

```
par(mfrow = c(1, 1))
```

Jeśli  $p < 0.05$  — **H3** potwierdzona.

## 11 Estymacja modelu GARCH-X

W równaniu średniej GARCH używamy regresorów *w pierwszych różnicach* (`r_Brent`, `r_EURUSD`, `d_Storage`, `d_HDD`) — są to dokładnie te same zmienne, na których przeprowadziliśmy selekcję w sekcji 6. Dla spójności metodologicznej w równaniu średniej GARCH stosujemy **wybrany podzbiór** regresorów (`selected_diff_vars`). W równaniu wariancji zostawiamy `Storage_pct` (poziom) — to osobny mechanizm: niskie zapasy → wyższa zmienność, niezależny od selekcji średniej.

```
returns_xts <- xts(df_diff$r_TTF, order.by = df_diff$Date)

all_mean_cols <- c("r_Brent", "r_EURUSD")
if (has_storage) all_mean_cols <- c(all_mean_cols, "d_Storage")
if (has_hdd)      all_mean_cols <- c(all_mean_cols, "d_HDD")

if (exists("selected_diff_vars") && length(selected_diff_vars) > 0) {
  ext_mean_cols <- selected_diff_vars
} else {
  ext_mean_cols <- all_mean_cols
}
ext_mean <- as.matrix(df_diff[, ext_mean_cols, drop = FALSE])

ext_var <- if (has_storage) {
  as.matrix(df_diff[, "Storage_pct", drop = FALSE])
} else {
  NULL
}

cat("Regresory w sredniej GARCH (po selekcji):",
    paste(ext_mean_cols, collapse = ", "), "\n")

## Regresory w sredniej GARCH (po selekcji): r_Brent, r_EURUSD, d_Storage

cat("Odrzucone w selekcji          :",
    paste(setdiff(all_mean_cols, ext_mean_cols), collapse = ", "),
    if (identical(ext_mean_cols, all_mean_cols)) "(zaden)" else "", "\n")

## Odrzucone w selekcji          : d_HDD

cat("Regresor w wariancji GARCH      :",
    if (has_storage) "Storage_pct (zawsze, niezalezne od selekcji sredniej)" else "(brak)", "\n")

## Regresor w wariancji GARCH      : Storage_pct (zawsze, niezalezne od selekcji sredniej)

arma_order <- c(fit_arimax$arma[1], fit_arimax$arma[2])
cat("Rzedy ARMA w GARCH (z fit_arimax po selekcji):", arma_order, "\n")

## Rzedy ARMA w GARCH (z fit_arimax po selekcji): 5 0
```

### 11.1 sGARCH(1,1) bazowy (bez X)

```
spec_base <- ugarchspec(
  variance.model = list(model = "sGARCH", garchOrder = c(1, 1)),
  mean.model     = list(armaOrder = arma_order, include.mean = TRUE),
  distribution.model = "std"
)
fit_garch_base <- ugarchfit(spec_base, data = returns_xts, solver = "hybrid")
fit_garch_base
```

```
##
## *-----*
## *          GARCH Model Fit          *
## *-----*
##
## Conditional Variance Dynamics
## -----
## GARCH Model   : sGARCH(1,1)
## Mean Model    : ARFIMA(5,0,0)
## Distribution   : std
##
## Optimal Parameters
## -----
##      Estimate Std. Error  t value Pr(>|t|)
## mu      0.000300   0.000797   0.376490 0.706552
## ar1     0.029890   0.024735   1.208396 0.226895
## ar2    -0.039513   0.024424  -1.617752 0.105716
## ar3    -0.009356   0.024088  -0.388428 0.697699
## ar4     0.058179   0.024034   2.420668 0.015492
## ar5    -0.001698   0.024107  -0.070421 0.943858
## omega   0.000031   0.000011   2.678345 0.007399
## alpha1  0.156018   0.023109   6.751298 0.000000
## beta1   0.842982   0.021014  40.115910 0.000000
## shape   6.504211   0.898245   7.241021 0.000000
##
## Robust Standard Errors:
##      Estimate Std. Error  t value Pr(>|t|)
## mu      0.000300   0.001054   0.284642 0.775918
## ar1     0.029890   0.022274   1.341880 0.179635
## ar2    -0.039513   0.022522  -1.754440 0.079355
## ar3    -0.009356   0.021417  -0.436869 0.662207
## ar4     0.058179   0.023210   2.506643 0.012188
## ar5    -0.001698   0.024875  -0.068246 0.945590
## omega   0.000031   0.000017   1.831288 0.067058
## alpha1  0.156018   0.025936   6.015550 0.000000
## beta1   0.842982   0.026349  31.992399 0.000000
## shape   6.504211   1.060777   6.131554 0.000000
##
## LogLikelihood : 3181.269
##
## Information Criteria
## -----
##
## Akaike      -3.5453
## Bayes      -3.5146
```

```

## Shibata      -3.5454
## Hannan-Quinn -3.5340
##
## Weighted Ljung-Box Test on Standardized Residuals
## -----
##               statistic p-value
## Lag[1]          1.056  0.3041
## Lag[2*(p+q)+(p+q)-1][14]    3.318  1.0000
## Lag[4*(p+q)+(p+q)-1][24]   11.672  0.5983
## d.o.f=5
## H0 : No serial correlation
##
## Weighted Ljung-Box Test on Standardized Squared Residuals
## -----
##               statistic p-value
## Lag[1]          0.0476  0.8273
## Lag[2*(p+q)+(p+q)-1][5]    0.3112  0.9825
## Lag[4*(p+q)+(p+q)-1][9]    1.9608  0.9096
## d.o.f=2
##
## Weighted ARCH LM Tests
## -----
##           Statistic Shape Scale P-Value
## ARCH Lag[3]    0.1859 0.500 2.000  0.6663
## ARCH Lag[5]    0.2864 1.440 1.667  0.9439
## ARCH Lag[7]    1.4813 2.315 1.543  0.8251
##
## Nyblom stability test
## -----
## Joint Statistic:  4.0332
## Individual Statistics:
## mu      0.27316
## ar1     0.35324
## ar2     0.07923
## ar3     0.20500
## ar4     0.22251
## ar5     0.10881
## omega   1.47744
## alpha1  0.47744
## beta1   0.63865
## shape   1.45202
##
## Asymptotic Critical Values (10% 5% 1%)
## Joint Statistic:      2.29 2.54 3.05
## Individual Statistic:  0.35 0.47 0.75
##
## Sign Bias Test
## -----
##               t-value   prob sig
## Sign Bias      0.005208 0.99585
## Negative Sign Bias 1.573096 0.11587
## Positive Sign Bias 1.439648 0.15014
## Joint Effect    8.400606 0.03842  **
##

```

```
##
## Adjusted Pearson Goodness-of-Fit Test:
## -----
##   group statistic p-value(g-1)
## 1     20      11.88      0.8906
## 2     30      28.56      0.4883
## 3     40      37.47      0.5396
## 4     50      57.81      0.1818
##
##
## Elapsed time : 0.4399352
```

## 11.2 sGARCH(1,1)-X — pełny

```
spec_x <- ugarchspec(
  variance.model = list(
    model          = "sGARCH",
    garchOrder     = c(1, 1),
    external.regressors = ext_var
  ),
  mean.model = list(
    armaOrder      = arma_order,
    include.mean   = TRUE,
    external.regressors = ext_mean
  ),
  distribution.model = "std"
)
fit_garch_x <- ugarchfit(spec_x, data = returns_xts, solver = "hybrid")
fit_garch_x
```

```
##
## *-----*
## *          GARCH Model Fit          *
## *-----*
##
## Conditional Variance Dynamics
## -----
## GARCH Model   : sGARCH(1,1)
## Mean Model    : ARFIMA(5,0,0)
## Distribution   : std
##
## Optimal Parameters
## -----
##      Estimate Std. Error  t value Pr(>|t|)
## mu      0.000000   0.000718  0.000386 0.999692
## ar1      0.024304   0.024488  0.992500 0.320954
## ar2     -0.048968   0.024508 -1.998010 0.045716
## ar3     -0.010342   0.023226 -0.445302 0.656101
## ar4      0.048513   0.021162  2.292463 0.021879
## ar5     -0.003128   0.022795 -0.137224 0.890854
## mxreg1    0.172544   0.031504  5.476912 0.000000
## mxreg2   -0.423172   0.114870 -3.683921 0.000230
```



```

## mxreg3  0.005497    0.001167  4.711424 0.000002
## omega   0.000000    0.000009  0.000006 0.999995
## alpha1  0.171936    0.024590  6.992180 0.000000
## beta1   0.838444    0.017932 46.757026 0.000000
## vxreg1  0.000000    0.000000  7.990976 0.000000
## shape   6.630697    0.948072  6.993872 0.000000
##
## Robust Standard Errors:
##      Estimate  Std. Error   t value Pr(>|t|)
## mu           0.000000   0.000874  0.000317 0.999747
## ar1           0.024304   0.022436  1.083243 0.278701
## ar2          -0.048968   0.022591 -2.167609 0.030188
## ar3          -0.010342   0.022109 -0.467783 0.639940
## ar4           0.048513   0.022328  2.172759 0.029798
## ar5          -0.003128   0.023695 -0.132011 0.894976
## mxreg1       0.172544   0.070740  2.439122 0.014723
## mxreg2      -0.423172   0.129592 -3.265409 0.001093
## mxreg3       0.005497   0.001354  4.059850 0.000049
## omega        0.000000   0.000007  0.000007 0.999994
## alpha1       0.171936   0.028690  5.992932 0.000000
## beta1        0.838444   0.021039 39.852257 0.000000
## vxreg1       0.000000   0.000000  6.877649 0.000000
## shape        6.630697   1.192674  5.559521 0.000000
##
## LogLikelihood : 3216.184
##
## Information Criteria
## -----
##
## Akaike          -3.5799
## Bayes           -3.5369
## Shibata         -3.5800
## Hannan-Quinn   -3.5640
##
## Weighted Ljung-Box Test on Standardized Residuals
## -----
##
##              statistic p-value
## Lag[1]                1.247  0.2642
## Lag[2*(p+q)+(p+q)-1] [14]    4.324  1.0000
## Lag[4*(p+q)+(p+q)-1] [24]   11.228  0.6650
## d.o.f=5
## H0 : No serial correlation
##
## Weighted Ljung-Box Test on Standardized Squared Residuals
## -----
##
##              statistic p-value
## Lag[1]                0.002303  0.9617
## Lag[2*(p+q)+(p+q)-1] [5]    0.723856  0.9183
## Lag[4*(p+q)+(p+q)-1] [9]    2.537776  0.8321
## d.o.f=2
##
## Weighted ARCH LM Tests
## -----
##
##              Statistic Shape Scale P-Value

```

```

## ARCH Lag[3]      0.4321 0.500 2.000 0.5109
## ARCH Lag[5]      0.6392 1.440 1.667 0.8419
## ARCH Lag[7]      2.0739 2.315 1.543 0.7017
##
## Nyblom stability test
## -----
## Joint Statistic: 10.3502
## Individual Statistics:
## mu      0.25630
## ar1     0.30733
## ar2     0.09413
## ar3     0.17240
## ar4     0.23453
## ar5     0.12246
## mxreg1  0.36946
## mxreg2  0.15151
## mxreg3  0.08190
## omega   2.39870
## alpha1  0.32784
## beta1   0.39528
## vxreg1  4.15957
## shape   0.99324
##
## Asymptotic Critical Values (10% 5% 1%)
## Joint Statistic:      3.08 3.34 3.9
## Individual Statistic: 0.35 0.47 0.75
##
## Sign Bias Test
## -----
##              t-value   prob sig
## Sign Bias      0.2937 0.76906
## Negative Sign Bias 1.8875 0.05926 *
## Positive Sign Bias 1.0729 0.28347
## Joint Effect    7.0983 0.06883 *
##
##
## Adjusted Pearson Goodness-of-Fit Test:
## -----
##   group statistic p-value(g-1)
## 1    20      24.11    0.19184
## 2    30      25.07    0.67465
## 3    40      52.05    0.07886
## 4    50      49.37    0.45819
##
##
## Elapsed time : 0.875433

```

### 11.3 Diagnostyka GARCH-X





```

std_resid_x <- as.numeric(residuals(fit_garch_x, standardize = TRUE))
ArchTest(std_resid_x, lags = 12)

```

```
##  
## ARCH LM-test; Null hypothesis: no ARCH effects  
##  
## data: std_resid_x  
## Chi-squared = 8.1153, df = 12, p-value = 0.7761
```

```
par(mfrow = c(4, 1))  
plot(fit_garch_x, which = 1)  
plot(fit_garch_x, which = 9)  
plot(fit_garch_x, which = 10)  
plot(fit_garch_x, which = 11)
```



Rysunek 7: Diagnostyka GARCH(1,1)-X

```
par(mfrow = c(1, 1))
```

## 11.4 Porównanie wariantów GARCH

```
spec_egarch <- ugarchspec(
  variance.model = list(model = "eGARCH", garchOrder = c(1, 1),
    external.regressors = ext_var),
  mean.model      = list(armaOrder = arma_order, include.mean = TRUE,
    external.regressors = ext_mean),
  distribution.model = "std"
)

spec_gjr <- ugarchspec(
  variance.model = list(model = "gjrGARCH", garchOrder = c(1, 1),
    external.regressors = ext_var),
  mean.model      = list(armaOrder = arma_order, include.mean = TRUE,
    external.regressors = ext_mean),
  distribution.model = "std"
)

fit_egarch <- ugarchfit(spec_egarch, returns_xts, solver = "hybrid")
fit_gjr <- ugarchfit(spec_gjr, returns_xts, solver = "hybrid")

ic_table <- tibble(
  Model = c("sGARCH(1,1)", "sGARCH(1,1)-X", "eGARCH(1,1)-X", "gjrGARCH(1,1)-X"),
  AIC = c(infocriteria(fit_garch_base)[1],
    infocriteria(fit_garch_x)[1],
    infocriteria(fit_egarch)[1],
    infocriteria(fit_gjr)[1]),
  BIC = c(infocriteria(fit_garch_base)[2],
    infocriteria(fit_garch_x)[2],
    infocriteria(fit_egarch)[2],
    infocriteria(fit_gjr)[2])
)

kable(ic_table, digits = 4, caption = "Kryteria informacyjne", booktabs = TRUE) |>
  kable_styling(latex_options = c("striped", "HOLD_position"))
```

Tabela 13: Kryteria informacyjne

| Model           | AIC     | BIC     |
|-----------------|---------|---------|
| sGARCH(1,1)     | -3.5453 | -3.5146 |
| sGARCH(1,1)-X   | -3.5799 | -3.5369 |
| eGARCH(1,1)-X   | -3.5879 | -3.5419 |
| gjrGARCH(1,1)-X | -3.5787 | -3.5327 |

## 12 Walidacja out-of-sample

```
split_date <- as.Date("2024-01-01")
idx_train <- which(df$Date < split_date)
idx_test  <- which(df$Date >= split_date)
cat("Trening :", length(idx_train), "obs.\n")
```

```
## Trening : 1558 obs.
```

```
cat("Test      :", length(idx_test), "obs.\n")
```

```
## Test       : 232 obs.
```

### 12.1 Walk-forward dla ARIMA / ARIMAX

```
y_all <- log(df$TTF)

oos_predict <- function(use_xreg) {
  preds <- rep(NA_real_, length(idx_test))
  for (i in seq_along(idx_test)) {
    t_end <- idx_test[i] - 1
    y_tr  <- y_all[1:t_end]
    if (use_xreg) {
      x_tr <- xreg_full[1:t_end, , drop = FALSE]
      x_new <- xreg_full[idx_test[i], , drop = FALSE]
      m <- tryCatch(
        Arima(y_tr, order = c(fit_arimax$arma[1], 1, fit_arimax$arma[2]),
              xreg = x_tr),
        error = function(e) NULL
      )
      if (!is.null(m)) preds[i] <- forecast(m, h = 1, xreg = x_new)$mean[1]
    } else {
      m <- tryCatch(
        Arima(y_tr, order = c(fit_arima$arma[1], 1, fit_arima$arma[2])),
        error = function(e) NULL
      )
      if (!is.null(m)) preds[i] <- forecast(m, h = 1)$mean[1]
    }
  }
  preds
}

pred_arima <- oos_predict(FALSE)
pred_arimax <- oos_predict(TRUE)
actual <- y_all[idx_test]

oos_metric <- function(pred, name) {
  err <- pred - actual
  tibble(Model = name,
```

```

    RMSE = sqrt(mean(err^2, na.rm = TRUE)),
    MAE = mean(abs(err), na.rm = TRUE),
    MAPE = mean(abs(err / actual), na.rm = TRUE) * 100)
}

oos_table <- bind_rows(
  oos_metric(pred_arima, "ARIMA"),
  oos_metric(pred_arimax, "ARIMAX")
)

kable(oos_table, digits = 4,
      caption = "Out-of-sample (2024): blad prognozy log-ceny TTF",
      booktabs = TRUE)

```

Tabela 14: Out-of-sample (2024): blad prognozy log-ceny TTF

| Model  | RMSE   | MAE    | MAPE   |
|--------|--------|--------|--------|
| ARIMA  | 0.0317 | 0.0261 | 0.7498 |
| ARIMAX | 0.0313 | 0.0258 | 0.7411 |

## 12.2 Test Diebolda-Mariano

```

dm <- dm.test(pred_arima - actual, pred_arimax - actual,
              alternative = "greater", h = 1, power = 2)
print(dm)

##
## Diebold-Mariano Test
##
## data:  pred_arima - actualpred_arimax - actual
## DM = 1.1757, Forecast horizon = 1, Loss function power = 2, p-value =
## 0.1205
## alternative hypothesis: greater

```

$H_0$ : równa trafność prognoz. Alternatywa: ARIMAX *lepszy* (mniejszy MSE).  $p < 0.05 \rightarrow$  **H5 potwierdzona**.

## 12.3 Wizualizacja prognoz OOS

```


tibble(
  Date = df$Date[idx_test],
  Actual = exp(actual),
  ARIMA = exp(pred_arima),
  ARIMAX = exp(pred_arimax)
) |>
pivot_longer(-Date, names_to = "Seria", values_to = "Cena") |>
ggplot(aes(Date, Cena, color = Seria, linetype = Seria)) +
  geom_line(linewidth = 0.6) +

```

```

scale_color_manual(values = c(Actual = "black", ARIMA = "steelblue",
                              ARIMAX = "darkred")) +
scale_linetype_manual(values = c(Actual = "solid", ARIMA = "dashed",
                                ARIMAX = "dashed")) +
labs(title = "Prognozy out-of-sample TTF (2024)",
     x = NULL, y = "Cena [EUR/MWh]") +
theme(legend.position = "bottom",
      legend.title = element_blank())

```



Rysunek 8: Prognozy 1-krokowe out-of-sample (2024)

**Obserwacje:** obie prognozy wizualnie pokrywają się z faktycznym przebiegiem ceny — zgodnie z testem Diebolda-Mariano ( $p = 0.12$ ) nie ma istotnej różnicy w jakości prognoz między ARIMA a ARIMAX. W prognozie 1-krokowej dziennej dominuje sygnał z ostatniej obserwacji TTF, regresory dodają marginalną informację.

## 13 Prognoza przyszła

### 13.1 ARIMAX ( $h = 30$ dni)

W bazowym scenariuszu zamrażamy regresory na ostatnim poziomie.

```

h <- 30
xreg_future <- matrix(rep(tail(xreg_full, 1), h), nrow = h, byrow = TRUE,
                      dimnames = list(NULL, colnames(xreg_full)))

```



```

fc_arimax <- forecast(fit_arimax, xreg = xreg_future, h = h)

# Konwersja do skali cenowej + manualny wykres z datami na osi X
future_dates <- seq.Date(max(df$Date) + 1, by = "day", length.out = h)

hist_df <- tibble(Date = df$Date, Cena = df$TTF) |>
  tail(180)
fc_df <- tibble(
  Date = future_dates,
  mean = exp(as.numeric(fc_arimax$mean)),
  lo80 = exp(as.numeric(fc_arimax$lower[, "80%"])),
  hi80 = exp(as.numeric(fc_arimax$upper[, "80%"])),
  lo95 = exp(as.numeric(fc_arimax$lower[, "95%"])),
  hi95 = exp(as.numeric(fc_arimax$upper[, "95%"]))
)

ggplot() +
  geom_ribbon(data = fc_df, aes(Date, ymin = lo95, ymax = hi95),
    fill = "steelblue", alpha = 0.2) +
  geom_ribbon(data = fc_df, aes(Date, ymin = lo80, ymax = hi80),
    fill = "steelblue", alpha = 0.4) +
  geom_line(data = hist_df, aes(Date, Cena), color = "black", linewidth = 0.5) +
  geom_line(data = fc_df, aes(Date, mean), color = "darkblue", linewidth = 0.7) +
  labs(title = paste("Prognoza ARIMAX na", h, "dni (z regresorami zamrozonymi)",
    subtitle = "Czarna linia: historia (ostatnie 180 sesji), niebieska: prognoza punktowa",
    x = NULL, y = "Cena [EUR/MWh]")

```

Prognoza ARIMAX na 30 dni (z regresorami zamrożonymi)  
Czarna linia: historia (ostatnie 180 sesji), niebieska: prognoza punktowa



Rysunek 9: Prognoza ARIMAX na 30 dni z 80% i 95% przedziałami ufności

## 13.2 GARCH-X (zmiennność warunkowa)



```
ext_var_future <- matrix(rep(tail(ext_var, 1), h), nrow = h, byrow = TRUE)
ext_mean_future <- matrix(rep(tail(ext_mean, 1), h), nrow = h, byrow = TRUE)

fc_garch_x <- ugarchforecast(
  fit_garch_x,
  n.ahead      = h,
  external.forecasts = list(mregfor = ext_mean_future, vregfor = ext_var_future)
)
print(fc_garch_x)
```

```
##
## *-----*
## *      GARCH Model Forecast      *
## *-----*
## Model: sGARCH
## Horizon: 30
## Roll Steps: 0
## Out of Sample: 0
##
## 0-roll forecast [T0=2024-11-29]:
##      Series  Sigma
## T+1  0.0013449  0.02477
```

```
## T+2  0.0009784 0.02550
## T+3  0.0015980 0.02622
## T+4  0.0022278 0.02693
## T+5  0.0016569 0.02762
## T+6  0.0016220 0.02831
## T+7  0.0016738 0.02898
## T+8  0.0017113 0.02965
## T+9  0.0016803 0.03031
## T+10 0.0016773 0.03096
## T+11 0.0016810 0.03160
## T+12 0.0016832 0.03224
## T+13 0.0016815 0.03288
## T+14 0.0016812 0.03350
## T+15 0.0016815 0.03412
## T+16 0.0016816 0.03474
## T+17 0.0016815 0.03535
## T+18 0.0016815 0.03596
## T+19 0.0016815 0.03657
## T+20 0.0016815 0.03717
## T+21 0.0016815 0.03776
## T+22 0.0016815 0.03836
## T+23 0.0016815 0.03895
## T+24 0.0016815 0.03953
## T+25 0.0016815 0.04012
## T+26 0.0016815 0.04070
## T+27 0.0016815 0.04128
## T+28 0.0016815 0.04186
## T+29 0.0016815 0.04244
## T+30 0.0016815 0.04301
```

```
par(mfrow = c(2, 1))
plot(fc_garch_x, which = 1)
plot(fc_garch_x, which = 3)
```



Rysunek 10: Prognoza warunkowej zmienności GARCH(1,1)-X

```
par(mfrow = c(1, 1))
```

## 14 Podsumowanie i wnioski

### 14.1 Weryfikacja hipotez

| Hipoteza                                          | Werdykt               | Uzasadnienie                                                                                                                                                                                                    |
|---------------------------------------------------|-----------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>H1:</b> TTF jest I(1)                          | <b>Potwierdzona</b>   | ADF na $\log(\text{TTF})$ ( $p = 0.833$ ) nie odrzuca niestacjonarności w poziomach; KPSS odrzuca stacjonarność ( $p = 0.010$ ). Po różnicowaniu ADF odrzuca ( $p = 0.010$ ), KPSS nie odrzuca ( $p = 0.100$ ). |
| <b>H2:</b> kointegracja TTF–Brent–EURUSD          | <b>Nieuzasadniona</b> | Engle-Granger: ADF na resztach $p = 0.070$ . Johansen ( $r = 0$ ): statystyka = 31.93 przy wartości krytycznej 5% = 34.91 (10% = 32.00).                                                                        |
| <b>H3:</b> efekt ARCH w resztach ARIMAX           | <b>Potwierdzona</b>   | ARCH-LM: $\chi^2 = 285.5$ , $p < 10^{-16}$ .                                                                                                                                                                    |
| <b>H4:</b> GARCH-X poprawia modelowanie wariancji | <b>Potwierdzona</b>   | AIC: sGARCH = -3.5453, sGARCH-X = -3.5799. BIC: sGARCH = -3.5146, sGARCH-X = -3.5369. Najlepszy po AIC: <b>eGARCH-X</b> , po BIC: <b>eGARCH-X</b> . Regresor wariancji Storage_pct: $t = 7.99$ , $p < 0.001$ .  |
| <b>H5:</b> ARIMAX > ARIMA OOS                     | <b>Odrzucona</b>      | Test Diebolda-Mariano: $DM = 1.18$ , $p = 0.120$ . RMSE: ARIMA = 0.0317, ARIMAX (po selekcji) = 0.0313.                                                                                                         |

## 14.2 Wnioski kluczowe

- **Stacjonarność (H1):** ceny TTF, Brent i EUR/USD są I(1); Storage\_pct stacjonarne wokół poziomu (z silną sezonowością roczną).
- **Kointegracja (H2):** ADF na resztach Engle-Grangera daje  $p = 0.070$ , Johansen statystyka 31.93 vs wartość krytyczna 5% 34.91. Brak silnej relacji długookresowej — formalnie nie uzasadnia budowy VECM. Brent pełni jednak rolę regresora krótkookresowego w ARIMAX (wsp. = 0.171 dla  $\log(\text{Brent})$ ,  $p < 0.001$ ).
- **ARIMAX vs ARIMA:** AICc ARIMA = -5490.39, ARIMAX pełny = -5532.32, ARIMAX po selekcji = -5532.41. BIC analogicznie: -5457.51 / -5477.55 / -5483.10. Regresory wnoszą istotną informację in-sample, ale różnica out-of-sample (1 krok dzienny) **nie jest** istotna statystycznie ( $DM\ p = 0.120$ ).
- **Heteroskedastyczność (H3):** silnie potwierdzona — ARIMAX bez warstwy GARCH nie domknie modelu (ARCH-LM  $\chi^2 = 285.5$ ).
- **GARCH-X (H4):** regresor Storage\_pct w równaniu wariancji **istotny statystycznie** ( $t = 7.99$ ). Po AIC preferowany model to **eGARCH-X**, po BIC **eGARCH-X**. Oba kryteria zgodne — wybór jednoznaczny.
- **Persystencja zmienności:**  $\hat{\alpha}_1 + \hat{\beta}_1 \approx 0.172 + 0.838 = 1.010$  — **suma przekracza 1** (formalnie niestacjonarna wariancja warunkowa, brak skończonej wariancji bezwarunkowej); rugarch w specyfikacji sGARCH nie wymusza ograniczenia  $\alpha + \beta < 1$  — wynik typowy dla rynków surowcowych po szoku strukturalnym 2022 r., wskazuje, że model na granicy IGARCH jest bliższy rzeczywistości niż klasyczny sGARCH.
- **Out-of-sample (H5):** regresory fundamentalne **nie poprawiają istotnie** prognozy 1-krokowej dziennej ceny w 2024 r. RMSE ARIMA = 0.0317 vs ARIMAX = 0.0313.

### 14.3 Ograniczenia i kierunki rozszerzeń

- **Efektywny zakres danych:** TTF z Kaggle obejmuje 2017-10-23 do 2024-11-29 (1790 sesji giełdowych). Brent i EUR/USD są dostępne wcześniej (od 2015), ale `inner join` ogranicza panel do okna TTF.
- **Engle-Granger z wartościami krytycznymi ADF:** standardowy ADF na resztach regresji kointegrującej używa niewłaściwych wartości krytycznych. Test Phillipsa-Ouliarisa (sekcja 7.2) daje formalnie poprawny werdykt.
- **Brak istotnej kointegracji** osłabia argumentację za włączeniem Brent jako “kotwicy cenowej” — Brent działa raczej jako współczynnik krótkookresowy (poprzez stopy zwrotu w GARCH-X).
- **VECM** nie ma uzasadnienia (brak kointegracji); naturalne rozszerzenie to **DCC-GARCH** (wielowymiarowa zmienność) lub **VAR** w stopach zwrotu.
- **Częstotliwość:** wszystkie szeregi sprowadzone do dziennej z LOCF dla luk weekendowych. Pełne wykorzystanie zmiennych miesięcznych (LNG, ERA5) wymagałoby modeli mixed-frequency (MIDAS) — poza zakresem.
- **Prognoza regresorów:** w horyzoncie 30 dni zamrożono regresory na ostatniej wartości. Rozszerzeniem byłoby modelowanie ścieżek `r_Brent` i `Storage_pct` osobnymi ARIMA i propagacja niepewności Monte Carlo.
- **Selekcja zmiennych** (sekcja 6, przed właściwym modelowaniem): zastosowano formalną procedurę *general-to-specific* na pomocniczej statycznej regresji OLS w pierwszych różnicach (regresory  $I(0)$ ,  $t$ -statystyki poprawne) — eliminacja wsteczna z progiem  $p > 0.10$  oraz porównanie modeli zagnieżdżonych po kryteriach AIC i BIC. Wszystkie 4 regresory mają uzasadnienie *a priori* mechanizmem ekonomicznym (substytucyjność Brent–TTF, kurs importu LNG, theory of storage, popyt sezonowy HDD); empirycznie zachowano tylko te, które przeszły test istotności statystycznej. Dalsze modele (ARIMAX, GARCH-X, prognoza, OOS) operują **na zbiorze po selekcji**, a model z pełnym zestawem regresorów pełni rolę punktu odniesienia (GUM — *general unrestricted model*). Alternatywą byłaby selekcja oparta na LASSO/Elastic Net z walidacją krzyżową szeregową (rolling-origin CV), co lepiej kontroluje overfitting w obecności wielu skorelowanych regresorów makro.